

Wydział: Fizyki i Informatyki Stosowanej

Kierunek: Informatyka Stosowana

Rok: 2020/21

Semestr: letni

Typ: stacjonarne

Nr albumu: 401984

Data: 07.06.2021



Sprawozdanie - Laboratorium nr 14
Generowanie ciągu liczb pseudolosowych o rozkładzie jednorodnym i
trójkątnym.

Spis treści

1	Wstęp teoretyczny	2
1.1	Rozkład prawdopodobieństwa	2
1.2	Rozkład trójkątny	3
1.3	Generator mieszany	4
1.4	Test χ^2	4
2	Zadanie do wykonania	5
2.1	Rozkład jednorodny	5
2.2	Rozkład trójkątny	5
3	Wyniki	6
4	Podsumowanie	8
5	Literatura	9


opracował:

Tomasz Szkaradek

1 Wstęp teoretyczny

1.1 Rozkład prawdopodobieństwa

Rozkład prawdopodobieństwa – miara probabilistyczna określona na zbiorze wartości pewnej zmiennej losowej (wektora losowego), przypisująca prawdopodobieństwa wartościom tej zmiennej. Formalnie rozkład prawdopodobieństwa można rozpatrywać bez odwołania się do zmiennych losowych.



Rysunek 1: Wybrane rozkłady gęstości prawdopodobieństwa:

$f_N(x)$ – rozkład normalny,

$f_E(x)$ – rozkład wykładniczy,

$f_R(x)$ – rozkład jednostajny,

$f_T(x)$ – rozkład trójkątny,

$f_D(x)$ – rozkład delty Diraca dla zmiennej pewnej

1.2 Rozkład trójkątny


Rozkład trójkątny - ten typ rozkładu jest użyteczny do opisu zmiennych losowych o stałej gęstości prawdopodobieństwa w obrębie określonego przedziału. Funkcję gęstości prawdopodobieństwa dla rozkładu trójkątnego $T(\mu, \Delta)$ definiujemy następująco:

$$f(x; \mu, \Delta) = \frac{-|x - \mu|}{\Delta^2} + \frac{1}{\Delta} \quad (1)$$

gdzie:

μ to środek rozkładu,

Δ to jego szerokość.



Jeśli $\xi_1 \in U(0, 1)$ i $\xi_2 \in U(0, 1)$ to zmienną o rozkładzie trójkątnym oraz parametrach μ i Δ generujemy stosując formułę

$$x = \mu + (\xi_1 + \xi_2 - 1) \cdot \Delta \quad (2)$$

Dystrybuanta tego rozkładu jest następująca

$$F(x) = \begin{cases} -\frac{1}{\Delta^2} \left(\frac{-x^2}{2} + \mu x \right) + \frac{x}{\Delta} - \left(-\frac{1}{\Delta^2} \cdot \left(\frac{-(\mu - \Delta)^2}{2} + \mu(\mu - \Delta) \right) + \frac{(\mu - \Delta)}{\Delta} \right) & x < \mu \\ -\frac{1}{\Delta^2} \cdot \left(\frac{x^2}{2} - \mu x \right) + \frac{x}{\Delta} - \left(-\frac{1}{\Delta^2} \left(\frac{\mu^2}{2} - \mu^2 \right) + \frac{\mu}{\Delta} \right) + \frac{1}{2} & x \geq \mu \end{cases} \quad (3)$$

1.3 Generator mieszany

Najbardziej znanym sposobem generowania liczb pseudolosowych jest metoda opracowana przez Lehmer'a w 1951 zwana liniowym generatorem kongruentnym. Polega ona na obliczaniu kolejnych liczb pseudolosowych: x_1, x_2, \dots, x_n o zakresie wartości $0, \dots, m-1$. Z generatora opracowanego przez Lehmer'a możemy otrzymać generator mieszany który wyraża się wzorem:

$$x_{i+1} = (a \cdot x_i + c) \bmod m \quad (4)$$

gdzie:

x_i kolejne pseudolosowe wartości

x_1 jest początkową wartością, którą inicjuje się generator - tzw. ziarnem

a, c, m parametry generatora

1.4 Test χ^2

Test zgodności χ^2 jest to najczęściej stosowany test nieparametryczny. Służy on do weryfikowania hipotezy, że obserwowana cecha X w zbiorowości generalnej ma określony typ rozkładu, np. dwumianowy, Poissona, normalny itd. Postać statystyki sprawdzającej hipotezy H_0

$$\chi^2 = \sum_{n=1}^K \frac{(n_i - n * p_i)^2}{n * p_i} \quad (5)$$

gdzie: n_i to ilość liczb znajdujących się w podprzedziale o indeksie i,

p_i to prawdopodobieństwo teoretyczne że zmienna losowa X znajdzie się w i-tym przedziale

$$p_i = F(x_i, max) - F(x_i, min) \quad (6)$$

F(X) jest wartością dystrybuanty (dla np. rozkładu trójkątnego obliczamy ją zgodnie ze wzorem [3])

Liczbę stopni swobody określamy jako $v = K - r - 1$

gdzie:

K jest liczbą podprzedziałów,

r = 2 jest liczbą parametrów testowanego rozkładu (σ i Δ)

2 Zadanie do wykonania

2.1 Rozkład jednorodny

Naszym pierwszym zadaniem w trakcie laboratoriów było napisać generator mieszany dla rozkładu jednorodnego korzystając z wzoru podanego na wstępie teoretycznym musimy wylosować $n = 10^4$ liczby pseudolosowych za pomocą naszego programu, startując od liczby $x_0 = 10$

$$x_{i+1} = (a \cdot x_i + c) \bmod m \quad (7)$$

o parametrach:

1. $a = 123$
 $c = 1$
 $m = 2^{15}$
2. $a = 69069$
 $c = 1$
 $m = 2^{32}$

Następnie dla obu tych przypadków rysujemy:

Wykres zależności $X_{i+1} = f(X_i)$

gdzie $X_i = x_i / (m + 1)$ z warunku normalizacji do rozkładu $U(0, 1)$

Histogram (dla $K = 12$ podprzedziałów) rozkładu gęstości prawdopodobieństwa dla $n = 10^4$ liczb pseudolosowych o rozkładzie równomiernym (oba przypadki).

Na sam koniec zadania 1 obliczamy wartości μ , σ i porównujemy z teoretycznymi.

2.2 Rozkład trójkątny

W następnym zadaniu będziemy się zajmować rozkładem trójkątnym: Na samym początku generujemy $n = 10^3$ liczby pseudolosowych według wzoru podanego we wstępie teoretycznym tj,

$$x = \mu + (\xi_1 + \xi_2 - 1) \cdot \Delta \quad (8)$$

dla parametrów $\Delta = 3$ $\sigma = 4$

Następnie dzielimy nasz przedział $[\mu - \Delta, \mu + \Delta]$ w którym znajdują się nasze liczby na $K=10$ równych podprzedziałów a następnie zliczamy ile liczb wpadło do każdego z tych podprzedziałów.

Dla rozkładu trójkątnego przeprowadzamy test χ^2 czyli określamy wartość statystyki testowej

$$\chi^2 = \sum_{n=1}^K \frac{(n_i - n * p_i)^2}{n * p_i} \quad (9)$$

W wykonujemy wykres gęstości naszego prawdopodobieństwa oraz histogram pokazujący wartości $\frac{n_i}{n}$ oraz p_i dla każdego z podprzedziałów.

Następnie testujemy hipotezę H_0 czy wygenerowany rozkład jest rozkładem $T(\mu, \Delta)$ wobec H_1 że nie jest to prawdą.


Korzystając z odpowiednich tabel statystycznych proszę sprawdzić czy nasza hipoteza jest prawdziwa na poziomie istotności $\alpha = 0.05$ (α jest prawdopodobieństwem pierwszego rodzaju czyli prawdopodobieństwem odrzucenia hipotezy H_0 gdy ta jest prawdziwa). W tym celu definiujemy obszar krytyczny testu:

$$\Phi = X : \chi^2(X) > \epsilon \quad (10)$$



gdzie: $X = x_1, x_2, \dots, x_n$ jest ciągiem liczb pseudolosowych, $\chi^2(X)$ wartością statystyki dla danego ciągu X , ϵ jest poziomem krytycznym danego rozkładu dla określonej liczby stopni swobody (określone w wstępie teoretycznym) i założonego poziomu istotności (należy odczytać z tabel statystycznych). Jeśli $\chi^2 < \epsilon$ to stwierdzamy że dla zadanego poziomu istotności nie ma podstaw do odrzucenia hipotezy H_0 .

3 Wyniki


Cały program został napisany w języku Python.



Rysunek 3: Wartości $\Delta_1 = 0.498$, $\sigma_1 = 0.287$



Rysunek 4: Wartości $\Delta_2 = 0.503$, $\sigma_2 = 0.288$



Rysunek 5: Histogram dla rozkładu trójkątnego

4 Podsumowanie

Podsumowując można powiedzieć że nie jesteśmy w stanie wygenerować ciągu liczb prawdziwie losowych z wykorzystaniem programów komputerowych wygenerowane liczby będą pseudolosowe. Pomiedzy kolejno wygenerowanymi liczbami zawsze będzie istniała jakaś zależność, jednak dzięki skorzystaniu z odpowiednich parametrów i funkcji będzie ona bardzo trudna do ustalenia i w konsekwencji ciąg liczbowy będzie trudny do odróżnienia od prawdziwie losowych liczb.

Możemy to wywnioskować na podstawie wygenerowanych wykresów 3 oraz 4 na których widać iż liczby nie pokrywają w pełni określonego obszaru.

Generator mieszany teoretycznie generuje liczby o rozkładzie jednorodnym, jednak dla małej liczby wylosowanych punktów pojawiają się pewne odchylenia w histogramach jednak będą się one zmniejszać wraz z liczbą generowanych punktów. Wyniki obliczonych wartości Δ oraz σ w obu przypadkach nieznacznie odbiegały (dla ustalonej dokładności ε_1 i ε_2) od wartości teoretycznych tj.

$$\Delta = \frac{0+1}{2} = 0.5 \quad (11)$$

$$\sigma = \frac{(1-0)}{\sqrt{12}} = 0,289 \quad (12)$$

$$|\Delta - \Delta_1| = |0.5 - 0.498| < \varepsilon_1$$

$$|\sigma - \sigma_1| = |0,289 - 0.287| < \varepsilon_2$$

$$|\Delta - \Delta_2| = |0.5 - 0.503| < \varepsilon_1$$

$$|\sigma - \sigma_2| = |0,289 - 0.288| < \varepsilon_2$$

co świadczy o poprawności zaimplementowanych generatorów które dają poprawne rezultaty i jak najbardziej spełniają swoje zadanie.

Podsumowując, zaletą generatorów liniowych jest prosta implementacja i szybkość działania. Przy odpowiednim doborze parametrów oraz zmiennym ziarnie można uzyskać liczby, które wyglądają na losowe i na pierwszy rzut oka nie mają widocznych zależności między kolejnymi wartościami. Dalej jednak układają się na hiperpłaszczyznach i aby tego uniknąć, należałoby zastosować inne generatory. Z otrzymanych przez nas wyników z 2 zadania to jest rozkład trójkątny możemy stwierdzić iż wylosowane przez nas wartości wmiare dokładnie oddają rozkład trójkątny co tylko potwierdza wykres 5 w którym kolejne wartości n_i/N układają się w trójkąt i nie odbiegają stanowczo od teoretycznych (tj.czerwona linia). Natomiast wykonany przez nas test χ^2 zdaje się to tylko potwierdzać prawdziwość naszych wyników

$$\chi^2 = \sum_{n=1}^K \frac{(n_i - n * p_i)^2}{n * p_i} = 5.63 \quad (13)$$

Odczytując z tablic wartość $\epsilon = 20,28$ poziomu krytycznego naszego rozkładu dla $K = 10, r = 2 \implies \nu = K - r - 1$ na poziomie istotności $\alpha = 0.05$ Możemy stwierdzić że dla danego poziomu istotności nie ma podstaw do odrzucenia hipotezy H_0 (wygenerowany rozkład jest rozkładem $T(\mu, \Delta)$) ponieważ:

$$\chi^2 < \epsilon \implies 5.63 < 20,28 \quad (14)$$

5 Literatura

- [1] Tomasz Chwiej, Generatory liczb pseudolosowych
<http://home.agh.edu.pl/~chwiej/mn/generatory-1819.pdf>
- [2] Wikipedia, Rozkład prawdopodobieństwa
https://www.wikiwand.com/pl/Rozk%C5%82ad_prawdopodobie%C5%84stwa